

Algorithmes à Estimation de Distribution et Finance Quantitative

Une approche probabiliste pour l'optimisation de portefeuille

Achraf Zahid Mohamed Amine El Arbani

Sous la coordination de
Pr. Abderrahim Azouani

May 23, 2026



Modèles probabilistes en évolution

Plan de la présentation

- 1 Du génétique au probabiliste : un changement de paradigme
- 2 Taxonomie des EDA : trois familles, trois complexités
- 3 Application réelle : la finance quantitative
- 4 Pourquoi les métaheuristiques standards échouent
- 5 EDA en action : du simple au sophistiqué
- 6 Synthèse et perspectives de recherche

Introduction : un défi persistant en optimisation

Contexte

Pendant des décennies, les **Algorithmes Génétiques (AG)** ont dominé l'optimisation évolutionnaire, imitant la sélection naturelle par *croisement*, *mutation* et *sélection*.

Mais un problème persiste...

Sur des problèmes complexes où les variables sont **fortement interdépendantes**, les AG classiques échouent systématiquement.

*Cette présentation raconte une révolution silencieuse :
le passage du génétique aveugle au probabiliste éclairé.*


La vulnérabilité des AG : la disruption des schémas

Un mécanisme aveugle

Le croisement et la mutation agissent de manière **aléatoire**, sans tenir compte des relations structurelles entre variables.

La conséquence

Dans les paysages **épistatiques** (où la fitness dépend de groupes coordonnés de variables), ces opérateurs **détruisent** les bonnes solutions partielles : on parle de *disruption de schémas*.



En une phrase

L'AG ne sait pas *ce qui marche ensemble* — il recombine au hasard.

La solution EDA : optimiser une distribution, pas des individus

Définition

Les **EDA** (*Estimation of Distribution Algorithms*), aussi appelés *Probabilistic Model-Building Genetic Algorithms*, abordent l'optimisation comme un **raffinement itératif d'une distribution de probabilité jointe** $p_I(x)$.

Différence fondamentale :


- **AG** : on manipule des *individus* (chromosomes) par hasard.
- **EDA** : on apprend *pourquoi* les bons individus sont bons, puis on échantillonne.

AG : Manipulation aveugle



EDA : Modélisation explicite

Le cycle opérationnel des EDA



Clé de l'approche

Au lieu de croiser *des individus*, on apprend la **distribution** qui les a générés, puis on en tire de nouveaux.

L'avantage maître : l'explicabilité

Le modèle probabiliste est lisible


Le modèle appris $p_I(x)$ se matérialise sous forme d'un **Graphe Probabiliste (PGM)** :

- Les **noeuds** = variables du problème.
- Les **arêtes** = dépendances apprises.

Bénéfice concret

Le décideur peut **inspecter** le graphe : quelles variables sont liées ? Quelles structures émergent ? Quel est le « squelette » du problème ?

C'est un atout décisif face à l'opacité des algorithmes évolutionnaires classiques.



Exemple de PGM : dépendances apprises entre variables.

De « comment ça marche » à « lequel choisir »

Une fois la philosophie EDA comprise, une question naturelle se pose :

La question centrale

Quel niveau de dépendance entre variables doit-on modéliser ?

La réponse à cette question divise les EDA en trois grandes familles, du plus simple au plus expressif :

- ① **Univariées** — Indépendance totale.
- ② **Bivariées** — Dépendances par paires.
- ③ **Multivariées** — Dépendances d'ordre supérieur.


Plus on monte, plus on capture. . . mais plus le coût computationnel grimpe.

Factorisations univariées : la simplicité radicale

Hypothèse

Toutes les variables sont **indépendantes**. La distribution jointe se factorise comme un produit de marginales :

$$p_I(x) = \prod_{i=1}^n p_I(x_i)$$



Aucune arête : indépendance totale.

Exemples

- **UMDA** (Univariate Marginal Distribution Algorithm)
- **PBIL** (Population-Based Incremental Learning)
- **cGA** (Compact Genetic Algorithm)

Avantage : Rapide, peu coûteux.

Limite : Aveugle à toute corrélation.

Factorisations bivariées : capturer les paires

Hypothèse


On modélise des dépendances **par paires**. Le graphe forme un *arbre* ou une *forêt* :

$$p_I(x) = p_I(x_r) \prod_{i \neq r} p_I(x_i \mid x_{\pi(i)})$$

Exemples

- **MIMIC** : structure en chaîne.
- **BMDA** : Bivariate Marginal Distribution Algorithm.
- **COMIT** : optimal tree structures.

Compromis : Bon équilibre expressivité / coût.



Structure arborescente : chaque variable a au plus un parent.


Factorisations multivariées : la puissance maximale

Hypothèse

On capture des dépendances d'**ordre supérieur**,
possiblement chevauchantes.

Deux approches phares

- **eCGA** (*extended Compact GA*) : regroupe les variables en **clusters disjoints** via le principe MDL (*Minimum Description Length*).
- **BOA / hBOA** (*(hierarchical) Bayesian Optimization Algorithm*) : utilise un **réseau bayésien** (DAG) pour des relations hiérarchiques complexes.




DAG : dépendances multiples et chevauchantes.

Force : Capture l'épistasie réelle.

Coût : Apprentissage de structure coûteux.

Synthèse visuelle des trois familles



À retenir

Le choix de la famille dépend de la **structure du problème** : un problème peu épistatique se contente d'un modèle simple ; un problème fortement couplé exige du multivarié.

De la théorie au terrain : pourquoi la finance ?

*Maintenant que la machinerie est posée, il faut un terrain d'application.
Et il en existe peu de plus exigeants que la finance.*

Pourquoi ce choix ?

La sélection de portefeuille combine :

- Des **variables discrètes** (quels actifs choisir ?)
- Des **variables continues** (avec quels poids ?)
- Des **contraintes dures** (budget, cardinalité, bornes)
- Une **forte épistase** (changer un actif force à redistribuer le reste)

C'est précisément le genre de paysage où les EDA dominent.

Le problème CCMV : Mean-Variance sous contrainte de cardinalité

Formulation

Sélectionner et pondérer K actifs parmi n pour minimiser le risque à rendement donné (ou maximiser le rendement à risque donné).

Formulation mathématique :

$$\min_w \underbrace{\sum_{i=1}^n \sum_{j=1}^n w_i w_j \sigma_{ij}}_{\text{Risque (variance)}} - \lambda \cdot \underbrace{\sum_{i=1}^n w_i \mu_i}_{\text{Rendement}}$$

Sous contraintes :

$$\sum_{i=1}^n w_i = 1, \quad \sum_{i=1}^n s_i = K, \quad \epsilon_i s_i \leq w_i \leq \delta_i s_i, \quad s_i \in \{0, 1\}$$

Lecture

$s_i = 1$ si l'actif i est sélectionné ; w_i = son poids dans le portefeuille.

Les contraintes : ce que la théorie classique ignore

1. Cardinalité K


Limite le nombre d'actifs actifs $\Rightarrow$ réduit les frais de transaction et simplifie la gestion.

2. Bornes ϵ et δ

Force chaque poids dans $[\epsilon_i, \delta_i]$ $\Rightarrow$ évite les positions infimes ou la sur-concentration.

3. Budget

Les poids somment à 1 : tout le capital est investi.



Conséquence

La frontière efficiente **n'est plus continue.**

La complexité : un mélange explosif

Nature du problème

La combinaison de :

- Variables **discrètes** (sélection $s_i \in \{0, 1\}$)
- Variables **continues** (poids $w_i \in [\epsilon_i, \delta_i]$)
- Une fonction objectif **non-convexe**

rend le problème **NP-difficile**.

Conséquences pratiques :

- Pas de solution analytique.
- Les méthodes exactes explosent au-delà de quelques dizaines d'actifs.
- Une **frontière efficiente discontinue** : de petits changements de K déplacent brutalement l'optimum.

Il faut donc une métaheuristique. Mais pas n'importe laquelle.

Le verdict : les AG standards ne suffisent pas

On pourrait penser qu'un bon AG ferait l'affaire. Trois raisons disent le contraire.

- ① **Épistasie variable** — actifs et poids sont fortement couplés.
- ② **Piège de l'infaisabilité** — le croisement viole les contraintes.
- ③ **Inefficacité** — les réparations dégradent les performances.

Examinons chaque point.

Obstacle 1 : l'épistasie entre sélection et poids


Le couplage caché

Changer la sélection s_i d'un actif force la **redistribution** de *tous* les poids restants pour respecter le budget.

⇒ *Toutes les variables sont liées entre elles, mais pas de manière simple.*

Pour un AG classique :

Le croisement échange des bits sans comprendre ce couplage ⇒ il **casse** les portefeuilles optimaux locaux.




Obstacle 2 : le piège de l'infaisabilité

Le problème

Le croisement aveugle d'un AG produit fréquemment des descendants qui :

- ont trop ou trop peu d'actifs sélectionnés ($\sum s_i \neq K$),
- ont des poids qui ne somment pas à 1,
- violent les bornes $[\epsilon_i, \delta_i]$.



Obstacle 3 : le coût des réparations

Solution adoptée par les AG classiques

Des *heuristiques de réparation* pour ramener les enfants infaisables dans l'espace admissible.

Mais à quel prix ?

- Coût computationnel **élevé** par génération.
- Réparations **biaisées** : elles tirent toujours la population dans la même direction.
- Résultat : **convergence prématurée** vers des optima locaux pauvres.

La promesse des EDA

Apprendre directement la **distribution** des portefeuilles *faisables et performants* $\Rightarrow$ aucun besoin de réparation. Les nouveaux échantillons respectent statistiquement les contraintes.

Deux exemples concrets pour deux niveaux de complexité

*Voyons maintenant deux EDA appliqués à la finance,
un de chaque famille extrême :*

A. PBIL-CCPS

Approche univariée

Probabilité indépendante par actif.
Rapide, élégant, scalable.

B. Copula-EDA

Approche multivariée non-linéaire

Modèle de dépendances par copules.
Robuste aux krachs et aux co-mouvements
extrêmes.

Le premier illustre l'efficacité. Le second illustre la sophistication.

A. PBIL-CCPS : un vecteur de probabilité comme mémoire

Mécanisme

On maintient un **vecteur de probabilité**

$v = (v_1, \dots, v_n)$ où v_i = probabilité que l'actif i soit sélectionné.


Mise à jour

À chaque génération, le vecteur est tiré vers les meilleurs portefeuilles via un taux d'apprentissage LR :

$$v_i^{(t+1)} = (1 - LR) v_i^{(t)} + LR \cdot \bar{x}_i^{\text{élite}}$$

Résultat

- Cartographie efficacement les frontières non-dominées.
- Coût computationnel **très inférieur** à un AG.



Le vecteur converge vers les actifs prometteurs.

B. Pourquoi le gaussien ne suffit plus en finance

Le présupposé des EDA continus classiques

Modéliser les rendements par une distribution **gaussienne multivariée** $\Rightarrow$ corrélations linéaires, queues symétriques.

La réalité des marchés

- Les actifs **chutent ensemble** pendant les crises (dépendance de queue).
- Les corrélations **ne sont pas linéaires**.
- Les distributions ont des **queues épaisses** (kurtosis élevée).

Le modèle gaussien sous-estime systématiquement le risque de crash.


Il faut un outil plus puissant : les copules.

Théorème de Sklar (1959)

Toute distribution jointe peut s'écrire comme :

$$F(x_1, \dots, x_n) = C(F_1(x_1), \dots, F_n(x_n))$$

- F_i : distributions marginales de chaque actif.
- C : **copule**, qui capture la structure de dépendance pure.



Copules archimédiennes et vine : capter le non-linéaire


Familles utilisées

- **Archimédiennes** (Clayton, Gumbel, Frank) : capturent des asymétries de queue.
- **Vine copulas** : décomposent une dépendance haute-dimension en cascade de copules bivariées.

Bénéfices pour l'EDA


- Capture des linkages **non-linéaires** et **multi-dimensionnels**.
- Navigation efficace dans un paysage **non-convexe**.
- Excellente **efficacité d'échantillonnage**.

Copule de Clayton (queue inf.)



Les points s'agglutinent près de (0,0) : krachs simultanés.

Bilan de la trajectoire



Nous tenons un cadre puissant. Mais où va la recherche ?

Direction 1 : l'hybridation des EDA

Idée

Combiner la **vision globale** des EDA avec la **précision locale** d'autres méthodes.

Combinaisons phares

- **hBOA + Hill Climber** : un EDA hiérarchique guide l'exploration, un grimpeur de colline raffine localement.
- **PBILDE** : marie PBIL (probabiliste) et *Differential Evolution* (continu, précis).

Pourquoi ça marche

Les EDA excellent à *trouver la bonne région* ; les méthodes locales excellent à *trouver le bon point*. Ensemble, on couvre les deux régimes.

Direction 2 : les cadres génératifs profonds

Idée

Remplacer les PGM classiques (réseaux bayésiens, arbres) par des **modèles génératifs profonds**.

Candidats

- **GAN** (*Generative Adversarial Networks*) : échantillons réalistes à grande échelle.
- **Modèles de diffusion** : génération haute fidélité, contrôlable.

Ce que cela débloque

La possibilité de scaler les EDA à des problèmes avec **des millions de variables** — impossible avec les modèles probabilistes classiques.

Une convergence prometteuse entre évolution et apprentissage profond.

En une phrase

Les EDA transforment l'optimisation évolutionnaire en **discipline statistique**, ouvrant la porte à des problèmes que les AG classiques ne pouvaient pas attaquer.


Trois idées à retenir

- ① Les EDA apprennent *pourquoi* les bonnes solutions sont bonnes — pas seulement *quelles* elles sont.
- ② La finance quantitative est un terrain idéal : forte épistasie, contraintes dures, paysage non-convexe.
- ③ L'avenir mêle EDA, optimisation locale et apprentissage profond.

« *Optimiser, ce n'est plus chercher au hasard.
C'est apprendre à chercher. »*

Merci pour votre attention

Questions & discussions



Achraf Zahid & Mohamed Amine El Arbani

Sous la coordination de **Pr. Abderrahim Azouani**